

# 総合実験1 倒立振子第2回： DC モーターのシステム同定

2025 年 4 月 17 日

## 第2回：モーターのシステム同定

この講義 (第2回) では、DC モーターの特性を実験データから理解し、制御設計の基礎となる\*\*システム同定\*\*の手法を学びます。

### システム同定とは？

- 入出力データに基づき、システムのモデルを決定するプロセス。
- モータのモデリングに不可欠⇒制御器設計に不可欠。

### 本日の目標

- 実験によるモーター応答データ収集。
- データに基づくパラメータ推定。
- 推定モデルの妥当性検証。

### 本日の流れ

- ① 理論 (モデル, 推定法)
- ② 実験 (データ収集)
- ③ データ処理・同定
- ④ 評価・検証
- ⑤ まとめ

# 理論：DC モーターの運動方程式

DC モーターの基本的な運動方程式（回転運動）は、トルクのバランスとして表されます。

$$J \frac{d^2\theta(t)}{dt^2} = \tau_m(t) - \tau_f(t) - \tau_l(t)$$

各項の意味：

- $J \frac{d^2\theta(t)}{dt^2}$ : 慣性モーメント ( $J$ )  $\times$  角加速度 ( $\ddot{\theta}$ )。慣性によるトルク。 $(J$ は通常未知)
- $\tau_m(t)$ : モーター発生トルク。電流  $I(t)$  に比例すると仮定 ( $= k_T I(t)$ )。  $k_T$  はトルク定数。 $(k_T$ は通常未知,  $I(t)$ は既知)
- $\tau_f(t)$ : 摩擦トルク。主に角速度  $\omega(t) = \dot{\theta}$  に依存。単純化のため粘性摩擦  $B\omega(t)$  を仮定。 $B$  は粘性摩擦係数。 $(B$ は通常未知)
- $\tau_l(t)$ : 外部からの負荷トルク。(今回は無視、または  $J$  に含まれると考える)

上記を角速度  $\omega(t)$ 、角加速度  $\alpha(t)$  で書き直すと、

$$J\alpha(t) = k_T I(t) - B\omega(t)$$

これはモーターの挙動を記述する基本的な物理モデルである。

# 理論：同定のための線形モデル

測定可能な量  $\alpha(t)$  について整理すると、

$$\alpha(t) = \left( \frac{k_T}{J} \right) I(t) - \left( \frac{B}{J} \right) \omega(t)$$

となります。ここで、比率  $\frac{k_T}{J}$  と  $\frac{B}{J}$  がモーターの特性を表す重要なパラメータとなります。

システム同定のための線形モデル表現:

推定したい未知パラメータを

$$a = \frac{k_T}{J}, \quad b = -\frac{B}{J}$$

とおくと、モデルは以下のシンプルな線形関係式で表せます。

$\underbrace{\alpha(t)}_{\substack{\text{角加速度} \\ \text{(測定/計算により既知)}}$	=	$\underbrace{a}_{\substack{\text{パラメータ 1} \\ \text{(未知・推定対象)}}$	·	$\underbrace{I(t)}_{\substack{\text{電流} \\ \text{(入力/測定により既知)}}$	+	$\underbrace{b}_{\substack{\text{パラメータ 2} \\ \text{(未知・推定対象)}}$	·	$\underbrace{\omega(t)}_{\substack{\text{角速度} \\ \text{(測定/計算により既知)}}$
---	---	---	---	--	---	---	---	--


**目標:** 実験で得られる時系列データ  $(\alpha, I, \omega)$  を使って、この線形モデルにおける未知のパラ

# 理論：必要な信号とノイズ源、そして数値微分

我々のモデル  $\alpha(t) = aI(t) + b\omega(t)$  を使うには、角速度  $\omega(t)$  と角加速度  $\alpha(t)$  が必要です。

## 1. 信号の取得と課題:

- 角度  $\theta(t)$  はセンサー (エンコーダ) で測定される。
- センサー出力は通常、**離散的**な値であり、真の連続値との間に**量子化誤差**が生じる。
- $\omega(t), \alpha(t)$  は  $\theta(t)$  から計算する必要がある。



## 2. 数値微分 (差分計算):

- 離散データから微分値を近似計算する中央差分:


$$\omega[k] \approx \frac{\theta[k+1] - \theta[k-1]}{2\Delta t}, \alpha[k] \approx \frac{\omega[k+1] - \omega[k-1]}{2\Delta t}$$

$\Delta t$  はサンプリング周期

# 理論：微分によるノイズ増幅とフィルタリング

## 問題点：数値微分はノイズを増幅する！

- センサーノイズや量子化誤差など、元の信号に含まれる高周波成分は、差分計算（微分）によってその影響が顕著になる。
- 特に二階微分である角加速度  $\alpha[k]$  は、ノイズの影響を非常に受けやすくなる。
- 下図（例）は、ノイズを含む信号とその微分（さらにノイズが増幅）を示す。



結果：ノイズの多い  $\omega[k], \alpha[k]$  をそのまま使うと、パラメータ推定 ( $a, b$ ) の精度が悪化。

## 解決策：ローパスフィルタリング

→ フィルタ処理された  $\omega[k], \alpha[k]$  を用いて、次のステップであるパラメータ推定を行う。

# 理論：最小二乗法への準備 (連立方程式)

## Step 1: 各時刻での関係式 (再掲)

フィルタリング後のデータを用い、各時刻  $t_k$  での関係式を考えます:

$$\alpha[k] \approx aI[k] + b\omega[k]$$

( $\alpha[k], I[k], \omega[k]$  は既知、 $a, b$  は未知)

## Step 2: 全データ点を連立方程式に

全データ点 ( $k = 1, \dots, N$ ) について、この関係式を書き並べると:

$$aI[1] + b\omega[1] \approx \alpha[1]$$

$$aI[2] + b\omega[2] \approx \alpha[2]$$

$$\vdots$$

$$aI[N] + b\omega[N] \approx \alpha[N]$$

( $N$  はデータ点の総数で、通常  $N \gg 2$  である)

## 理論：最小二乗法の行列表現

以下の行列  $\mathbf{X}$ 、ベクトル  $\beta$ 、ベクトル  $\mathbf{y}$  を用いて

$$\mathbf{X}\beta \approx \mathbf{y}$$

と簡潔に書ける。

$$\underbrace{\begin{bmatrix} I[1] & \omega[1] \\ I[2] & \omega[2] \\ \vdots & \vdots \\ I[N] & \omega[N] \end{bmatrix}}_{\substack{\mathbf{X} \ (N \times 2) \\ \text{計画行列} \\ \text{(既知)}}} \underbrace{\begin{bmatrix} a \\ b \end{bmatrix}}_{\substack{\beta \ (2 \times 1) \\ \text{パラメータ} \\ \text{(未知)}}} \approx \underbrace{\begin{bmatrix} \alpha[1] \\ \alpha[2] \\ \vdots \\ \alpha[N] \end{bmatrix}}_{\substack{\mathbf{y} \ (N \times 1) \\ \text{観測ベクトル} \\ \text{(既知)}}}$$

### 課題 (再掲):

実際のデータにはノイズが含まれるため、方程式  $\mathbf{X}\beta = \mathbf{y}$  を厳密に満たす  $\beta$  は通常存在しない。



# 理論：最小二乗解

## Step 3: 誤差最小化によるパラメータ推定

方程式  $\mathbf{X}\boldsymbol{\beta} \approx \mathbf{y}$  において、「最も当てはまりの良い」未知パラメータ  $\boldsymbol{\beta}$  を見つけるために、誤差の二乗和  $\|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|^2$  を最小化する。

この最小化問題の解  $\hat{\boldsymbol{\beta}}$  は、以下の式（正規方程式の解）で与えられる。

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

ここで、

- $\mathbf{X}^T$  は行列  $\mathbf{X}$  の転置 (Transpose)。
- $(\mathbf{X}^T \mathbf{X})^{-1}$  は行列  $\mathbf{X}^T \mathbf{X}$  の逆行列 (Inverse Matrix)。
- $\hat{\boldsymbol{\beta}} = \begin{bmatrix} \hat{a} \\ \hat{b} \end{bmatrix}$  が推定されたパラメータ。

**実装上の注意:** プログラムでは、数値安定性のため  $(\mathbf{X}^T \mathbf{X})^{-1}$  を直接計算せず、QR 分解や SVD (例: `'numpy.linalg.lstsq'`) を用いるのが一般的である。