

総合実験1 倒立振子 第6回：
強化学習による倒立制御
試行錯誤からの学習 ～AI がバランスを学ぶ～

2025 年 5 月 22 日

本日の実験目的 (第6回)

- 強化学習の基本的な考え方と用語を具体例を通して理解する。
 - エージェント、環境、行動、状態、そして最も重要な報酬と方策。
 - 「教師あり学習」と何が違うのか？
- Python と Webots シミュレータを使い、AI（強化学習エージェント）に倒立振子のバランスを取る方法を学習させる。
- 今回採用する強化学習手法「SAC」の概要と、なぜそれを使うのかを知る。
- 倒立振子を立たせるための「良い」報酬の与え方について考える。
- AI の学習過程と、学習後の動きを観察・評価する。

1. 強化学習とは？ ～身近な例え～

アイデア：「試行錯誤」と「フィードバック（ご褒美や罰）」を通じて、賢いやり方（方策）を学ぶこと。

犬のしつけ:

- 犬 (エージェント) は色々な行動を試す。
- 「お手」をしたら：おやつゲット！（良い報酬）
- 「吠えたら」：無視される（良くない結果）
- 学習結果：おやつがもらえる行動をだんだん多くするようになる。

ゲームの攻略:


- プレイヤー (エージェント) はステージクリアを目指す。
- アイテムを取ると：スコアアップ！（良い報酬）
- 敵に当たると：ゲームオーバー（大きな罰）
- 学習結果：スコアを稼ぎ、ゲームオーバーを避ける動きを覚えていく。

強化学習の基本要素：エージェントと環境の対話

方策 (Policy) π

「何をすべきか」

強化学習ループ（時刻 t で繰り返す）



- エージェント (**Agent**): 学習し、意思決定を行うプログラム。今回の主役。
- 環境 (**Environment**): エージェントが行動する対象。今回は倒立振子。
- 状態 (S_t): ある瞬間の環境の様子（例: 振子の角度、角速度）。
- 行動 (A_t): エージェントが状態 S_t で行う操作（例: モーターへの電圧）。
- 報酬 (R_{t+1}): 行動 A_t の結果、環境から与えられる「ご褒美」または「罰」。

なぜ倒立振子に強化学習を使うのか？

従来の制御手法（例：PID 制御、状態フィードバック）の課題

- 倒立振子の正確な**数学モデル（運動方程式）**が必要なが多い。
- モデル化できない要素（摩擦、バックラッシュ、センサーノイズ等）の影響を扱いにくい。
- パラメータ（ゲイン）調整が難しい。試行錯誤が必要なのは同じだが、体系的な最適化が難しい。
- 非線形性が強いシステムの最適な制御器設計は非常に困難。

強化学習のアプローチと期待

- モデルフリー
- 複雑なダイナミクスの学習データを通じて暗黙的に学習できる。
- 最適な制御方策の発見：人間が思いつかないような優れた制御方策を自律的に見つけ出すかも。
- 目標設定の柔軟性：報酬関数を通じて多様な目標を設定可能。

ただし、強化学習も万能ではない！

- 学習に時間がかかる：多くの試行錯誤（データ）が必要。
- **報酬設計が難しい**：何を「良い」とするか、適切に設定しないと期待しない行動を学習すること。
- 実機学習の危険性：学習初期は不安定な行動を取りがちなので、実機の場合は安全対策が必須。

報酬設計：AIに「何をすべきか」を教える鍵

エージェントは、ここで設計された**合計報酬を最大にする**ように行動を学習します。

1. ピッチ角に基づく基本報酬

- 目的: **倒立**を促す。
- 計算: $reward = \exp(-e_{coeff} \times |\theta_{pitch}|)$
- 振子の傾きが0に近いほど報酬は1に近づく。

2. 安定ボーナス

- 目的: より**安定**の倒立を促す。
- 条件: if $|\theta_{pitch}| < \epsilon_{threshold}$
- 追加報酬: $reward+ = b_{stable}$ (stable bonus)

3. 車輪動作の不一致ペナルティ

- 目的: 左右の車輪が**協調してスムーズに**動くことを奨励。無駄な動きを抑制。
- 計算: $penalty = p_{coeff} \times (a_L - a_R)^2$
- 減算: $reward- = penalty$

4. 転倒ペナルティ (重要だが注意点あり！)

- 目的: **転倒を避ける**こと。
- 条件: if $|\theta_{pitch}| > \theta_{fall}$
- ペナルティ: $reward+ = p_{fall}$

学習の目標

これらの報酬ルールを通じて、倒立振子ができるだけ長く、より安定して直立し続け、かつスムーズに動作するように学習。

最終レポートについて

記載内容:

- レポートに記載すべき詳細な内容については、BEEF+で配布されている「**総合実験 A 指導書**」をよく確認してください。

提出について:

- 提出期限: **5 月 29 日 17 : 00** です。**厳守**してください。
- 提出方法: 完成したレポートを **BEEF Plus** で**提出** してください。

注意事項:

- 実験を進める中で、レポート作成に必要なデータの**取り忘れないように**注意してください。
- 取得したデータは、**各班で責任を持って整理・共有**し、バックアップも検討しましょう。
- レポートの書き方や体裁については、指導書巻末の「**レポート作成例**」を**必ず参照**してください。